Университет ИТМО, факультет программной инженерии и компьютерной техники
Двухнедельная отчётная работа по «Информатике»: аннотация к статье

Дата прошедшей лекции	Номер прошедшей лекции	Название статьи/главы книги/видеолекции	Дата публикации (не старше 2022 года)	Размер статьи (от 400 слов)	Дата сдачи
10.09.2025	1	Компьютеры на основе тернарной логики и перспективы их развития.	12.10.2022	~12500	24.09.2025
24.09.2025	2	Алгоритм сжатия информации с использованием нумерации перестановок.	2025	~1750	08.10.2025
08.10.2025	3	Enhanced Regular Expression as a DGL for Generation of Synthetic Big Data	2023	~6800	22.10.2025
	4				
	5				
	6				
	7				

Выполнил(а) Шалабодов Я.Д., № группы *P3110*, оценка _____
Фамилия И.О. студента — не заполнять

Прямая полная ссылка на источник или сокращённая ссылка:
https://jips-k.org/digital-library/manuscript/file/38429/01-(1_16)%2021E01-007-ME-ed(0222)-r1(0227)%20end.pdf

Теги, ключевые слова или словосочетания:
Big Data Analytics, Data Generation Language (DGL), Performance Analysis, Regular Expression, Synthetic Data Generation, Type/format Inference

Перечень фактов, упомянутых в статье:
1. Основа для языка генерации данных DGL - регулярные выражения.
2. Для DGL предложены важные расширения: data domains, type/format inference, resource reference.
3. Два основных типа доменов для синтеза осмысленных данных: *set* и *range.*
4. Для выборки данных из доменов используются два типа примитивных генераторов: seq() и rng().
5. Поддерживаются различные вероятностные распределения: равномерное, нормальное, Пуассона, Ципфа, для создания скошенных данных, характерных для реальных наборов.
6. В синтаксис регулярных выражений введена новая конструкция — ссылка на ресурс %{name}.
7. На примере бенчмарка TPC-H показано, что предложенный DGL может легко определять значения для отдельных колонок, а также генерировать внешние ключи.
8. Для повышения эффективности генерации предложено и экспериментально проверено RegExp Caching и DB Caching.

Позитивные следствия и/или достоинства описанной в статье технологии.
1. Расширенные регулярные выражения позволяют точно описывать сложные шаблоны данных, включая ссылки на внешние словари, базы данных и последовательности.
2. Технология позволяет генерировать данные со сложными вероятностными распределениями, внешними ключами и data skew.
3. Возможность интеграции с файлами упрощает процесс подготовки данных для тестирования и анализа.

Негативные следствия и/или недостатки описанной в статье технологии.
1. Язык может стать сложным для чтения и сопровождения при описании очень сложных иерархических данных или данных с многочисленными взаимосвязями.
2. Генерация данных на основе сложных регулярных выражений с множественными ссылками на внешние ресурсы и вероятностными распределениями может быть затратной при создании очень больших наборов данных.
3. Для обеспечения сложной логики и семантической целостности потребуется дополнительный уровень валидации или генерации, выходящий за рамки языка, т.к. DGL лучше подходит для определения формата и статистических распределений данных.